

计算理论

第1章 正则语言

孙岩炜

网络空间安全学院

2025 年 9月



有穷自动机的形式化定义

定义 1.1

➤ 有穷自动机是一个 5 元组 $(Q, \Sigma, \delta, q_0, F)$, 其中


(1) Q 是一个有穷集合, 称为**状态集**。

(2) Σ 是一个有穷集合, 称为**字母表**。

(3) $\delta: Q \times \Sigma \rightarrow Q$ 是**转移函数**。

(4) $q_0 \in Q$ 是**起始状态**。

(5) $F \subseteq Q$ 是**接受状态集**。



计算的形式化定义

定义 1.7

➤ 设 $M = (Q, \Sigma, \delta, q_0, F)$ 是一台有穷自动机, $w = w_1w_2 \cdots w_n$ 是一个字符串, 并且 w_i 是字母表 Σ 的成员。如果存在 Q 中的状态序列 $r_0, r_1, \dots, r_n$, 满足下列条件:

- 1) $r_0 = q_0$
- 2) $\delta(r_i, w_{i+1}) = r_{i+1}, \quad i = 0, 1, \dots, n-1$
- 3) $r_n \in F$

则 M 接受 w 。

➤ 如果 $A = \{w \mid M \text{ 接受 } w\}$, 则称 A 是机器 M 的语言, 记作 $L(M) = A$, 又称 M 识别 (recognize) 语言 A 或 M 接受 (accept) A 。

➤ 如果一个语言被一台有穷自动机识别, 则称它是正则语言。


计算的形式化定义举例

例 1.8

➤ 给定有穷自动机 M_5 的状态图如下。令 w 是字符串

$10\langle\text{RESET}\rangle 22\langle\text{RESET}\rangle 012$

给出 M_5 对 w 计算时进入的状态序列。



$q_0 \sim q_1 \sim q_1 \sim q_0 \sim q_2 \sim q_1 \sim q_0 \sim q_0 \sim q_1 \sim q_0$

$L(M_5) = \{w \mid \text{除} \langle\text{RESET}\rangle \text{将计数重新置} 0 \text{外, 所有符号之和模 } 3 \text{ 等于 } 0\}$

正则运算

定义 1.10

➤ 设 A 和 B 是两个语言，定义正则运算并、连接和星号如下：

(1) 并： $A \cup B = \{x \mid x \in A \text{ 或 } x \in B\}$

(2) 连接： $A \circ B = \{xy \mid x \in A \text{ 且 } y \in B\}$

(3) 星号： $A^* = \{x_1x_2 \cdots x_k \mid k \geq 0 \text{ 且每一个 } x_i \in A\}$

例 1.11

➤ 设字母表 Σ 是标准的 26 个字母 $\{a, b, \dots, z\}$ 。又设 $A = \{\text{good}, \text{bad}\}$, $B = \{\text{boy}, \text{girl}\}$, 求 $A \cup B$, $A \circ B$ 和 A^* 。

$A \cup B = \{\text{good}, \text{bad}, \text{boy}, \text{girl}\}$

$A \circ B = \{\text{goodboy}, \text{goodgirl}, \text{badboy}, \text{badgirl}\}$

$A^* = \{\epsilon, \text{good}, \text{bad}, \text{goodgood}, \text{goodbad}, \text{goodgoodgood}, \dots\}$


正则运算

定理 1.12


- 正则语言类在并运算下封闭，即：
如果 A_1 和 A_2 是正则语言，则 $A_1 \cup A_2$ 也是正则语言。

证明思路

$$M_1 = (\{x_0, x_1, x_2, \dots, x_n\}, \{0, 1\}, \delta, x_0, \{x_n\})$$



$$M_2 = (\{y_0, y_1, y_2, \dots, y_m\}, \{0, 1\}, \delta, y_0, \{y_m\})$$




正则运算

定理 1.12

- 正则语言类在并运算下封闭，即：
如果 A_1 和 A_2 是正则语言，则 $A_1 \cup A_2$ 也是正则语言。

证明思路




正则运算

定理 1.12

- 正则语言类在并运算下封闭，即：
如果 A_1 和 A_2 是正则语言，则 $A_1 \cup A_2$ 也是正则语言。

证明思路



正则运算

定理 1.12

- 正则语言类在并运算下封闭，即：
如果 A_1 和 A_2 是正则语言，则 $A_1 \cup A_2$ 也是正则语言。

证明

设 $M_1 = (Q_1, \Sigma, \delta_1, q_1, F_1)$ 识别 A_1 , $M_2 = (Q_2, \Sigma, \delta_2, q_2, F_2)$ 识别 A_2 。

构造识别 $A_1 \cup A_2$ 的 $M = (Q, \Sigma, \delta, q_0, F)$:

(1) $Q = Q_1 \times Q_2 = \{(r_1, r_2) \mid r_1 \in Q_1 \text{ 且 } r_2 \in Q_2\}$: 笛卡尔积

(2) 字母表不变

(3) $\delta((r_1, r_2), a) = (\delta_1(r_1, a), \delta_2(r_2, a))$

(4) $q_0 = (q_1, q_2)$

(5) $F = \{(r_1, r_2) \mid r_1 \in F_1 \text{ 或 } r_2 \in F_2\}$


正则运算

定理 1.12

- 正则语言类在并运算下封闭，即：
如果 A_1 和 A_2 是正则语言，则 $A_1 \cup A_2$ 也是正则语言。

证明思路

$$\begin{aligned} M_1 &= (\{x_0, x_1, x_2, \dots, x_n\}, \{0,1\}, \delta, x_0, \{x_n\}) \\ M_2 &= (\{y_0, y_1, y_2, \dots, y_m\}, \{0,1\}, \delta, y_0, \{y_m\}) \end{aligned} \Rightarrow M = \left(\begin{aligned} &\{(x_0, y_0), (x_1, y_1), \dots, (x_n, y_m)\}, \\ &\{0,1\}, \\ &\delta, \\ &(x_0, y_0) \\ &\{(x_n, y_0), (x_n, y_1), \dots, (x_0, y_m), (x_1, y_m), \dots\} \end{aligned} \right)$$



自动机 M_1 与 M_2 分别针对 $A_1 \cup A_2$ 中的字符串进行状态转移，**一定会** 转移到 x_n 状态或者 y_m 状态。

正则运算

定理 1.13

- 正则语言类在连接运算下封闭，即：
如果 A_1 和 A_2 是正则语言，则 $A_1 \circ A_2$ 也是正则语言。

证明

设 M_1 识别 A_1 ， M_2 识别 A_2 。

如何构造识别 $A_1 \circ A_2$ 的 $M = (Q, \Sigma, \delta, q_0, F)$?

证明思路： M_1 接受第一段且 M_2 接受第二段时， M 才接受。

举例： $A_1 = \{1, 01, 11, 001, \dots\}$ (以 1 结尾)

$A_2 = \{0, 000, 00000, \dots\}$ (奇数个 0)

$w = 0011000$

❓ 第一段和第二段的分界点在哪? ➡ 引入非确定性



计算理论

Contents

目录

1 有穷自动机

2 非确定性


3 正则表达式

4 非正则语言

非确定性

对比

- **确定性有穷自动机 (DFA)**：当机器处于给定状态时，若给定一个输入，则下一个状态是**唯一确定**的。
- **非确定性有穷自动机 (NFA)**：当机器处于给定状态时，若给定一个输入，则下一个状态**可能不唯一**，而且允许转移箭头上有 ϵ 。



转换规则：一入多出




ϵ 是空字：无入转态


非确定性

举例

➤ 非确定性有穷自动机状态图如下：




➤ q_1 状态下，输入为1时：



下一个状态可能是 q_1 或 q_2 。

➤ q_2 状态下，无输入时：



下一个状态可能是 q_3 。


是否接受 0110 ？

接受： $q_1 \rightarrow q_1 \rightarrow q_2 \rightarrow q_3 \rightarrow q_4 \rightarrow q_4$


非确定性

举例

➤ 非确定性有穷自动机状态图如下：




➤ q_1 状态下，输入为 1 时：



下一个状态可能是 q_1 或 q_2 。

➤ q_2 状态下，无输入时：





下一个状态可能是 q_3 。

是否接受 1?

拒绝: $q_1 \rightarrow q_1 \times$, $q_1 \rightarrow q_2 \times$, $q_1 \rightarrow q_2 \rightarrow q_3 \times$

非确定性



➤ 输入为 010110 时的状态转换过程



构造非确定性自动机

例 1.14


- 设 A 是 $\{0, 1\}$ 上倒数第三个符号为 1 的所有字符串组成的语言，构造非确定性自动机识别 A 。



非确定性自动机接受的语言

例 1.15

- 考虑图示的 NFA N_3 ，其输入字母表 $\{0\}$ 由一个符号组成。
只含一个符号的字母表称为**一元字母表**。考虑它接受的语言。




$$L(N) = \{ w = 0^k \mid k \text{ 是 } 2 \text{ 或 } 3 \text{ 的倍数} \}$$

非确定性自动机接受的语言

例 1.16

➤ 考虑图示的 NFA N_4 。运行这台机器，判断其是否识别 $\varepsilon, a, baba, baa, b, bb, babba$ 。



N_4 接受 $\varepsilon, a, baba, baa$, 拒绝 $b, bb, babba$

NFA 的形式化定义

定义1.17

➤ 非确定型有穷自动机 (NFA) 是一个 5 元组 $(Q, \Sigma, \delta, q_0, F)$,

- (1) Q 是有穷的状态集。
- (2) Σ 是有穷的字母表。
- (3) $\delta: Q \times \Sigma_{\varepsilon} \rightarrow P(Q)$ 是转移函数。
- (4) $q_0 \in Q$ 是起始状态。
- (5) $F \subseteq Q$ 是接受状态集。

注：对比和DFA的差异, $\Sigma_{\varepsilon} = \Sigma \cup \{\varepsilon\}$


NFA 计算的形式化定义

定义1.17

- 设 $N = (Q, \Sigma, \delta, q_0, F)$ 是一台 NFA, $w = y_1y_2 \dots y_m$ 是一个字符串, 并且 $y_i \in \Sigma_\epsilon$ 。如果存在 Q 中的状态序列 $r_0, r_1, \dots, r_m$, 满足下列条件:
- 1) $r_0 = q_0$
 - 2) $r_{i+1} \in \delta(r_i, y_{i+1}), i = 0, 1, \dots, m-1$
 - 3) $r_m \in F$
- 则 N 接受 w 。

NFA 举例

例 1.18



$$N = (Q, \Sigma, \delta, q_1, F)$$

$$Q = \{q_1, q_2, q_3, q_4\}$$

$$\Sigma = \{0, 1\}$$


$$F = \{q_4\}$$

	0	1	ε
q_1	$\{q_1\}$	$\{q_1, q_2\}$	$\emptyset$
q_2	$\{q_3\}$	$\emptyset$	$\{q_3\}$
q_3	$\emptyset$	$\{q_4\}$	$\emptyset$
q_4	$\{q_4\}$	$\{q_4\}$	$\emptyset$

非确定性自动机计算的形式化定义

例 1.21


➤ 将图示的 NFA N 转换成等价的 DFA。



$$Q = \{ \emptyset, \{1\}, \{2\}, \{3\}, \{1,2\}, \{1,3\}, \{2,3\}, \{1,2,3\} \}$$

$$E(\{1\}) = \{1, 3\}$$

$$F = \{ \{1\}, \{1,2\}, \{1,3\}, \{1,2,3\} \}$$



非确定性自动机计算的形式化定义

定理 1.19

➤ 每一台非确定型有穷自动机都等价于某一台确定型有穷自动机。

➤ 定义:

$$E(R) = \{ q \mid \text{从 } R \text{ 出发沿着 } 0 \text{ 个或多个 } \varepsilon \text{ 箭头可以到达 } q \}$$

➤ 设 $N = (Q, \Sigma, \delta, q_0, F)$ 识别语言 A

构造DFA $M = (Q', \Sigma, \delta', q'_0, F')$, $L(M) = L(N)$

(1) $Q' = P(Q)$, $R \in Q'$ 和 $a \in \Sigma$

$$\delta'(R, a) = \cup_{r \in R} E(\delta(r, a))$$

$$q'_0 = E(\{q_0\})$$

$$F' = \{R \in Q' \mid R \cap F \neq \emptyset\}$$


此即为 N 对应的DFA M 。

正则运算的封闭性

定理 1.22

➤ 正则语言类在并运算下封闭。

证明思路



设 $N_1 = (Q_1, \Sigma, \delta_1, q_1, F_1)$

$N_2 = (Q_2, \Sigma, \delta_2, q_2, F_2)$

构造 $N = (Q, \Sigma, \delta, q_0, F)$

$$\delta(q, a) = \begin{cases} \delta_1(q, a) & q \in Q_1 \\ \delta_2(q, a) & q \in Q_2 \\ \{q_1, q_2\} & q = q_0 \wedge a = \varepsilon \\ \emptyset & q = q_0 \wedge a \neq \varepsilon \end{cases}$$

正则运算的封闭性

定理 1.22

➤ 正则语言类在并运算下封闭。

证明


设 $N_1 = (Q_1, \Sigma, \delta_1, q_1, F_1)$ $N_2 = (Q_2, \Sigma, \delta_2, q_2, F_2)$

构造 $N = (Q, \Sigma, \delta, q_0, F)$

$$Q = \{q_0\} \cup Q_1 \cup Q_2$$

1. q_0 是 N 的起始状态
2. 转移函数:
3. $F = F_1 \cup F_2$

$$\delta(q, a) = \begin{cases} \delta_1(q, a) & q \in Q_1 \\ \delta_2(q, a) & q \in Q_2 \\ \{q_1, q_2\} & q = q_0 \wedge a = \varepsilon \\ \emptyset & q = q_0 \wedge a \neq \varepsilon \end{cases}$$





正则运算的封闭性

定理 1.23

➤ 正则语言类在连接运算下封闭。


证明思路

设 $N_1 = (Q_1, \Sigma, \delta_1, q_1, F_1)$ 识别 A_1 , $N_2 = (Q_2, \Sigma, \delta_2, q_2, F_2)$ 识别 A_2



构造 $N = (Q, \Sigma, \delta, q, F)$ 识别 $A_1 \circ A_2$:

1. $Q = Q_1 \cup Q_2$
2. $q = q_1$
3. $F = F_2$
4. 转移函数 $\delta(q, a) =$:



$$\begin{cases} \delta_1(q, a), & q \in Q_1 \text{ 且 } q \notin F_1 \\ \delta_1(q, a), & q \in F_1 \text{ 且 } a \neq \varepsilon \\ \delta_1(q, a) \cup \{q_2\}, & q \in F_1 \text{ 且 } a = \varepsilon \\ \delta_2(q, a), & q \in Q_2 \end{cases}$$


正则运算的封闭性

定理 1.24

➤ 正则语言类在星运算下封闭。

证明思路

设 $N_1 = (Q_1, \Sigma, \delta_1, q_1, F_1)$



构造 $N = (Q, \Sigma, \delta, q_0, F)$

1. $Q = \{q_0\} \cup Q_1$
2. q_0 是新的起始状态
3. $F = \{q_0\} \cup F_1$



为什么不直接将原起始状态
加到接收状态集?

$$\delta(q, a) = \begin{cases} \delta_1(q, a), & q \in Q_1 \text{ 且 } q \notin F_1 \\ \delta_1(q, a), & q \in F_1 \text{ 且 } a \neq \varepsilon \\ \delta_1(q, a) \cup \{q_1\}, & q \in F_1 \text{ 且 } a = \varepsilon \\ \{q_1\}, & q = q_0 \text{ 且 } a = \varepsilon \\ \emptyset, & q = q_0 \text{ 且 } a \neq \varepsilon \end{cases}$$



计算理论

1 | 有穷自动机

2 | 非确定性

3 | 正则表达式

4 | 非正则语言

引入

- 在算术中，可以用+和 $\times$ 构造表达式，如 $(5+3)\times 4$ 。
- 类似地，可以用正则运算符构造描述语言的表达式，称为正则表达式。

举例

- 考察正则表达式 $(0 \cup 1)0^*$
- 0 和 1 是 $\{0\}$ 和 $\{1\}$ 的简写， $(0 \cup 1) = (\{0\} \cup \{1\}) = \{0, 1\}$
- $0^* = \{0\}^*$ ，即任意个0组成的字符串
- 正则表达式中常省略连接符， $(0 \cup 1)0^* = (0 \cup 1) \circ 0^*$

正则表达式

例 1.25

- 考察正则表达式 $(0 \cup 1)^* = \Sigma^*$
 - 若 $\Sigma = \{0, 1\}$, 则可以用 Σ 作为 $(0 \cup 1)$ 的缩写。
 - Σ^* 表示该字母表上的所有字符串组成的语言。
 - Σ^*1 是包含所有以 1 结尾的字符串的语言。
 - $(0\Sigma^*) \cup (\Sigma^*1)$ 由所有以 0 开始或者以 1 结尾的字符串组成。

正则表达式的形式化定义

定义 1.26

➤ 称 R 是一个正则表达式, 如果 R 是

(1) $a, a \in \Sigma$;

(2) ε ;

(3) $\emptyset$;

(4) $R_1 \cup R_2$, R_1 和 R_2 是正则表达式;

(5) $R_1 \circ R_2$, R_1 和 R_2 是正则表达式;

(6) R_1^* , R_1 是正则表达式;

正则表达式举例

例 1.27

➤ 假定字母表 $\Sigma = \{0, 1\}$, 下列都是合法的正则表达式。

$$(1) 0^*10^*$$

$$(2) \Sigma^*1\Sigma^*$$

$$(3) \Sigma^*001\Sigma^*$$

$$(4) (01^+)^*$$

$$(5) (\Sigma\Sigma)^*$$

$$(6) (\Sigma\Sigma\Sigma)^*$$

$$(7) 01 \cup 10 = \{01, 10\}$$

$$(8) 0\Sigma^*0 \cup 1\Sigma^*1 \cup 0 \cup 1$$

$$(9) (0 \cup \varepsilon)1^* = 01^* \cup 1^*$$

$$(10) (0 \cup \varepsilon)(1 \cup \varepsilon) = \{0, 1, 01, \varepsilon\}$$

$$(11) 1^*\emptyset = \emptyset$$

$$(12) \emptyset^* = \{\varepsilon\}$$

注：区分正则表达式 R , 其描述语言 $L(R)$.

$$R^+ = RR^*, R^+ \cup \varepsilon = R^*, R^k = R \cdots R \text{ (} k \text{ 个)}$$

正则表达式的性质

性质

(1) $R \cup \emptyset = R$

(2) $R \circ \varepsilon = R$

(3) $R \cup \varepsilon = R$ 可能不成立

例：如果 $R = 0$ ，那么 $L(R) = \{0\}$ ，而 $L(R \cup \varepsilon) = \{0, \varepsilon\}$

(4) $R \circ \emptyset = R$ 可能不成立

例如，如果 $R = 0$ ，那么 $L(R) = \{0\}$ ，而 $L(R \circ \emptyset) = \emptyset$

定理 1.28

➤ 一个语言是正则的，当且仅当可以用正则表达式描述它。

正则表达式与有穷自动机的等价性

引理 1.29

➤ 如果一个语言可以用正则表达式描述，那么它是**正则**的。

证明


把 R 转换成一台 NFA N
考虑 R 的 6 种情况

- (1) $R = a$
- (2) $R = \varepsilon$
- (3) $R = \emptyset$
- (4) $R = R_1 \cup R_2$
- (5) $R = R_1 \circ R_2$
- (6) $R = R^*$


(1) $N = (\{q_1, q_2\}, \Sigma, \delta, q_1, \{q_2\})$

当 $r \neq q_1$ 或 $b \neq a$ 时,


$\delta(q_1, a) = \{q_2\}, \delta(r, b) = \emptyset$



(2) $N = (\{q_1\}, \Sigma, \delta, q_1, \{q_1\})$
 $\delta(r, b) = \emptyset$



(3) $N = (\{q\}, \Sigma, \delta, q, \emptyset)$
 $\delta(r, b) = \emptyset$







(4)(5)(6): 利用正则语言的封闭性

正则表达式与有穷自动机的等价性

例 1.31

- 将正则表达式 $(a \cup b)^* aba$ 转换成 NFA



正则表达式与有穷自动机的等价性

引理 1.32

➤ 一个语言是正则的，则可以用正则表达式描述它。


证明

引入广义非确定型有穷自动机 GNFA：

- (1) 转移箭头可以用任何正则表达式作标号；
- (2) 起始状态全部射出箭头，无摄入箭头；
- (3) 有唯一的一个接受状态，无射出箭头，全摄入箭头；
- (4) 接受状态和起始状态不同。除起始状态和接受状态外，每一个状态到自身和到其它每一个状态都有一个箭头。

广义非确定型有穷自动机

GNFA举例



广义非确定型有穷自动机

定义 1.33

➤ **广义非确定有穷自动机** GNFA $M = (Q, \Sigma, \delta, q_{\text{start}}, q_{\text{accept}})$

(1) Q 是有穷的状态集。

(2) Σ 是输入字母表。

(3) $\delta : (Q - \{q_{\text{start}}\}) \times (Q - \{q_{\text{accept}}\}) \rightarrow R$ 是转移函数。

注: R 是 Σ 上的全体正则表达式的组成的集合。

(4) q_{start} 是起始状态。

(5) q_{accept} 是接受状态。

※自动机的 **边** 推广为 **正则表达式** (子程序,子自动机)

➤ 通过增加新的起始状态和接受状态, 可以将 **DFA** 转换成 **GNFA**。

正则表达式与有穷自动机的等价性


引理 1.32

➤ 一个语言是正则的，则可以用正则表达式描述它。

证明

证明思路：

- (1) 正则语言有 DFA M 识别，再把 DFA M 转化为广义的 GNFA
- (2) 把广义的 GNFA 转化称正则表达式



DFA 转化为 GNFA

引理 1.32

➤ 一个语言是正则的，则可以用正则表达式描述它。



证明

DFA $\rightarrow$ GNFA 思路：

- 1、添加1个新的起始状态和接收状态，新旧起始状态/接收状态转移有 ε 箭头（加首尾）
- 2、如果一个箭头有多个标记，则替换成原有标记并集的箭头（合并符号）
- 3、没有箭头的状态之间增加 $\emptyset$ 箭头（补空边）

GNFA转化为正则表达式

GNFA状态减少



法则：用力拉首尾，拓扑变形。以星换圈，以并换多路

DFA转正则表达式

例 1.36

➤将下列 DFA 转化为正则表达式。

